

Solver Pentadiagonal Híbrido CPU–GPU com Ajuste Dinâmico por Simulated Annealing para o Benchmark NPB SP

André Gualberto¹, Gabriel Thomaz do Nascimento¹

¹Laboratório Nacional de Computação Científica (LNCC)
Av. Getúlio Vargas, 333 – 25651-075 – Petrópolis – RJ – Brasil

agualber@lncc.br, thomazgb@lncc.br

Abstract. *The scalar pentadiagonal solver of the NAS Parallel Benchmark (NPB SP) is a memory- and latency-bound workload in which GPUs typically achieve modest speedups. This work presents a hybrid CPU–GPU implementation of the pentadiagonal sweep in which the fraction of lines assigned to each processing unit is adjusted at runtime by a simulated annealing (SA) heuristic that minimizes the measured time of each sweep window. The implementation was validated for reproducibility by bit-identical checksums across 1000 iterations, and executed with thermal monitoring via NVML. On an NVIDIA RTX 5000 Ada, the hybrid solver solved 1.061,191,680,000 points (1.061 trillion) as 1,040,384,000 linear systems of order 1020 in 213.9 s, at 163 ms per sweep and 182 GFLOPS (28 flops/point estimate), surpassing both the pure-GPU (185 ms) and pure-CPU (611 ms) modes. The same adaptive scheme reached 4.86 million pentadiagonal systems per second, in the same order as the NPB-GPU CUDA reference (200–216 GFLOPS, NAS official counting) on the same hardware.*

Resumo. *O solver pentadiagonal escalar do benchmark NAS Parallel Benchmark (NPB SP) é uma carga de trabalho limitada por memória e latência, na qual GPUs tipicamente atingem acelerações modestas. Este trabalho apresenta uma implementação híbrida CPU–GPU da varredura pentadiagonal em que a fração de linhas atribuída a cada unidade de processamento é ajustada em tempo de execução por uma heurística de simulated annealing (SA) que minimiza o tempo medido de cada janela de varredura. A implementação foi validada quanto à reprodutibilidade por checksums bit-idênticos ao longo de 1000 iterações e executada com monitoramento térmico via NVML. Em uma NVIDIA RTX 5000 Ada, o solver híbrido resolveu 1.061.191.680.000 pontos (1,061 trilhão), correspondentes a 1.040.384.000 sistemas lineares de ordem 1020, em 213,9 s, a 163 ms por varredura e 182 GFLOPS (estimativa de 28 flops/ponto), superando tanto o modo somente-GPU (185 ms) quanto o somente-CPU (611 ms). O mesmo esquema adaptativo atingiu 4,86 milhões de sistemas pentadiagonais por segundo, na mesma ordem do NPB-GPU CUDA de referência (200–216 GFLOPS, contagem oficial NAS) no mesmo hardware.*

1. Introdução

Sistemas lineares de banda estreita surgem em inúmeras aplicações científicas: métodos ADI para equações parabólicas, aproximações finitas-diferenças de ordem superior, splines cúbicas e o passo implícito de esquemas de fatoração aproximada em CFD. O benchmark NAS Parallel Benchmarks (NPB) SP [Bailey et al. 1991] sintetiza essa classe

de problemas: a cada passo de tempo são resolvidas varreduras de sistemas pentadiagonais escalares independentes ao longo das três direções da malha.

Do ponto de vista de desempenho, o NPB SP é reconhecidamente uma das cargas mais difíceis de acelerar em GPU [Araujo et al. 2021]. A razão é estrutural: cada linha resolve uma cadeia de dependências serial (eliminação de Thomas), com baixa intensidade aritmética e padrões de acesso que penalizam a hierarquia de cache. Em contrapartida, as GPUs modernas possuem banda de memória abundante, mas só a exploram plenamente quando há paralelismo em massa com dependências curtas.

Neste contexto, este trabalho apresenta um solver híbrido CPU–GPU da varredura pentadiagonal do NPB SP com três contribuições principais:

- **Ajuste dinâmico por simulated annealing:** a fração de linhas atribuída à CPU e à GPU é decidida em tempo real por uma heurística SA que mede o custo real de cada janela de varredura, sem exigir conhecimento prévio da máquina nem calibração manual;
- **Reprodutibilidade numérica:** aritmética estrita (compilação com `-fmad=false`) e verificação por checksum bit-idêntico em todas as iterações, garantindo que o balanceamento adaptativo não altera os resultados;
- **Operação monitorada:** telemetria NVML de temperatura e consumo a cada lançamento de kernel, com trava térmica de segurança.

Os experimentos foram executados em uma NVIDIA RTX 5000 Ada Generation e resultaram na resolução de **1,061 trilhão de pontos** em 213,9 s, superando os modos puros somente-GPU e somente-CPU na mesma máquina (Seção 5). O restante do artigo está organizado como segue: a Seção 2 revisa os trabalhos relacionados; a Seção 3 descreve o método (problema pentadiagonal, arquitetura híbrida, ajuste dinâmico por SA e telemetria); a Seção 4 apresenta a plataforma experimental e o protocolo de validação; a Seção 5 apresenta os resultados e a comparação com a literatura; e a Seção 7 conclui.

2. Trabalhos Relacionados

O estado da arte em solvers de banda em GPU divide-se em três vertentes: bibliotecas batch, implementações custom de alta eficiência e portes do próprio NPB.

Bibliotecas batch. O cuSPARSE oferece rotinas interleaved de Thomas para tridiagonais (`gtsvInterleavedBatch`) e pentadiagonais (`gpsvInterleavedBatch`). Carroll *et al.* desenvolveram o cuPentBatch [Carroll et al. 2019], um solver pentadiagonal batch que mantém uma única cópia da matriz do sistema e atualiza apenas os vetores de termos independentes, superando a NVIDIA em até cerca de $2\times$ nos casos de interesse físico. Um pôster técnico da NASA [Jackson and Zubair 2021] demonstrou ganhos de 92% sobre a NVIDIA, atribuindo o ganho à menor demanda de banda de memória. Enquanto PfSolve [Tolmachev et al. 2025] e bibliotecas Multi-GPU (PaScaL-TDMA [Kang et al. 2023], Pipelined-TDMA [Kim et al. 2025]) focam em escalabilidade horizontal de hiper-grafos, o solver SPIKE [Chang et al. 2012] estabelece a base de estabilidade numérica. Nossa abordagem contrapõe frameworks de nó único como StarPU [Augonnet et al. 2011].

NPB em GPU. O NPB-GPU [Araujo et al. 2021], mantido por Araujo, Griebler e colaboradores (PUCRS), porta os oito benchmarks do NPB para CUDA, HIP e GSParLib e reporta o SP como um dos de menor aceleração em GPU. Neste artigo, o NPB-GPU foi

compilado e executado na mesma placa que o solver proposto, permitindo comparação quantitativa direta com a contagem oficial de flops da NAS (Seção 5).

Nenhum dos trabalhos anteriores combina, de forma automática e em tempo de execução, o balanceamento CPU–GPU via otimização metaheurística com reprodutibilidade numérica bit-a-bit — a lacuna que este trabalho endereça. Do lado dos runtimes, o StarPU [Augonnet et al. 2011] escalona tarefas heterogêneas em tempo de execução, mas por grafo de tarefas e sem otimização metaheurística da fração CPU/GPU.

3. Método

3.1. O problema pentadiagonal

A varredura x-solve do NPB SP resolve, para cada linha da malha, um sistema pentadiagonal da forma

$$a_i u_{i-2} + b_i u_{i-1} + c_i u_i + d_i u_{i+1} + e_i u_{i+2} = f_i, \quad i = 1, \dots, n, \quad (1)$$

com condições de contorno tratadas por redução das bandas nas extremidades. A resolução direta usa eliminação de Thomas estendida [Thomas 1949] (fatoração LU das cinco diagonais), $O(n)$ flops e acesso serial aos coeficientes.

3.1.1. Fatoração LU da matriz pentadiagonal

Seja $A = (a_{ij})$ a matriz pentadiagonal $n \times n$ associada a (1): os elementos não nulos de uma linha i são $a_i \equiv a_{i,i-2}$, $b_i \equiv a_{i,i-1}$, $c_i \equiv a_{i,i}$, $d_i \equiv a_{i,i+1}$ e $e_i \equiv a_{i,i+2}$, com todos os elementos fora das cinco diagonais nulos. A fatoração $A = LU$ sem pivotamento [Golub and Van Loan 2013] produz L bidiagonal inferior com diagonal unitária e U com banda superior de largura 2, cujos elementos obedecem às recorrências

$$l_{i,i-2} = a_i / u_{i-2,i-2}, \quad l_{i,i-1} = (b_i - l_{i,i-2} u_{i-2,i-1}) / u_{i-1,i-1}, \quad (2)$$

$$u_{i,i} = c_i - l_{i,i-1} u_{i-1,i} - l_{i,i-2} u_{i-2,i}, \quad u_{i,i+1} = d_i - l_{i,i-1} u_{i-1,i+1}, \quad u_{i,i+2} = e_i,$$

para $i = 1, \dots, n$, com as condições de contorno tratadas separadamente. A solução de $Ax = f$ segue por substituição direta e retrossubstituição ($y_i = f_i - l_{i,i-1} y_{i-1} - l_{i,i-2} y_{i-2}$ e $x_i = (y_i - u_{i,i+1} x_{i+1} - u_{i,i+2} x_{i+2}) / u_{i,i}$).

Cada linha exige 28 operações em ponto flutuante por ponto [Golub and Van Loan 2013]. A varredura `solve_lines_kernel` elimina a sub-diagonal (Eq. 2) seguida da substituição para obter x . As recorrências são idênticas nas CPUs e GPU, invocadas com `-fmad=false` no host para evitar contrações matemáticas que introduzam diferenças de arredondamento.

Neste trabalho a malha é representada como `nb` blocos de `lines_per_block=256` linhas consecutivas de $n=1020$ pontos. Cada bloco é uma porção contígua do vetor de estado, permitindo lançamento coalescido de kernels na GPU e atribuição granular de trabalho entre CPU e GPU.

3.2. Arquitetura híbrida

A Figura 1 ilustra a arquitetura. Os blocos livres são mantidos em uma lista encadeada compartilhada (“livre”). Um thread *dispatcher* consome a lista em lotes de `BATCH` blocos e, para cada lote, decide quantos blocos vão para a CPU (pool de $N = 16$ threads POSIX — metade dos 32 threads do EPYC 9124 —, cada uma executando a eliminação serial) e quantos vão para a GPU — decisão $O(1)$ por bloco, em contraste com o grafo de tarefas

de runtimes como o StarPU [Augonnet et al. 2011]. Os blocos de GPU são acumulados em um vetor `pending[]` e lançados em *mega-lotes* de MEGA=128 blocos (um único kernel `solve_lines_kernel` e uma única sincronização), reduzindo os *launches* a 32 por varredura de 4064 blocos. O Algoritmo 1 descreve a varredura híbrida completa: enquanto o *dispatcher* decide a destinação de cada lote e acumula os blocos de GPU em `pending[]`, os threads de CPU consomem seus blocos concorrentemente.

```

1: Entrada: lista livre, fração  $x$ , coeficientes; Saída: contadores gpu_blocks, cpu_done
2:  $npend \leftarrow 0$ 
3: while a lista livre não está vazia do
4:   pega lote de BATCH blocos da lista
5:   calcula  $to\_gpu \leftarrow$  blocos do lote para GPU;  $to\_cpu \leftarrow$  resto
6:   for cada bloco destinado à CPU do
7:     move bloco para a fila da CPU
8:   end for
9:   for cada bloco destinado à GPU do
10:     $pending[npend++] \leftarrow$  bloco
11:   end for
12:   if  $npend \geq$  MEGA then
13:     telemetria NVML e verificação da trava térmica
14:     lança solve_lines_kernel com  $npend$  blocos; sincroniza;  $npend \leftarrow 0$ 
15:   end if
16:   atualiza janela do decisor SA (Algoritmo 2)
17: end while
18: lança o mega-lote residual e sincroniza

```

▷ threads de CPU resolvem concorrentemente

Algoritmo 1. Varredura híbrida completa — thread *dispatcher* (esquerda) e threads de CPU (direita), executados concorrentemente.




Figura 1. Arquitetura do solver híbrido: dispatcher com decisor SA, integração Out-of-Core com Memória Swap, pool de threads CPU (EPYC 9124), mega-lotes de kernels GPU e telemetria NVML.

Os coeficientes do sistema (cinco diagonais) são copiados uma única vez para a GPU (`d_l1-d_u2`); apenas o vetor de termos independentes varia entre blocos, no mesmo esquema de matriz-única/RHS-múltipla do `cuPentBatch` [Carroll et al. 2019]. O RHS é gerado uma única vez antes do laço de iterações, com a mesma aritmética do preenchimento serial. Os resultados das linhas de CPU são escritos diretamente no buffer do host e os de GPU no buffer de dispositivo; o checksum de verificação é calculado apenas em iterações amostradas (primeira, última e a cada 100), com redução OpenMP.

3.3. Ajuste dinâmico por simulated annealing

Seja $x_j \in [x_{\min}, x_{\max}]$ a fração de trabalho atribuída à CPU na janela j , e seja Δt_j o tempo real gasto pelo dispatcher para consumir a janela deslizante de $W = \text{SA_WIN}$ blocos. O custo medido da decisão corrente é o tempo médio por bloco da janela:

$$E_j = E(x_j) = \frac{\Delta t_j}{W}. \quad (3)$$

O objetivo é minimizar (3) em relação à fração x . Como E_j é uma função não-convexa e dependente do estado transiente da máquina, adota-se o critério de aceitação de Metropolis [Metropolis et al. 1953]: dada uma nova fração candidata x' extraída por um passo

aleatório, a fração x' substitui a corrente ($x_{j+1} = x'$) com probabilidade

$$P(\text{aceitar } x') = \begin{cases} 1, & \text{se } E(x') \leq E(x_j), \\ e^{-(E(x')-E(x_j))/T_j}, & \text{caso contrário,} \end{cases} \quad (4)$$

onde a temperatura termodinâmica decresce geometricamente [Kirkpatrick et al. 1983]

$$T_{j+1} = \alpha T_j, \quad \alpha = \text{SA_ALPHA} \in (0, 1), \quad (5)$$

e o novo candidato é gerado por perturbação uniforme no intervalo $[-\text{SA_DX}, +\text{SA_DX}]$, truncada aos limites físicos:

$$x_{j+1} = \text{clip}(x_j + \mathcal{U}[-\text{SA_DX}, +\text{SA_DX}], x_{\min}, x_{\max}). \quad (6)$$

Quando T_j atinge a temperatura de congelamento T_{freeze} , a fração passa a ser fixada em x_{best} , a melhor observada. O Algoritmo 2 formaliza o ciclo de decisão usado a cada janela.

```

1: Entrada: estado corrente ( $E_{\text{prev}}, x_{\text{prev}}$ ), melhor ( $E_{\text{best}}, x_{\text{best}}$ ), temperatura  $T$ , custo medido  $E(x')$ 
2:  $x' \leftarrow \text{clip}(x_j + \mathcal{U}[-\text{SA\_DX}, +\text{SA\_DX}], x_{\min}, x_{\max})$  ▷ (6)
3: if  $E(x') \leq E_{\text{prev}}$  then ou  $u < e^{-(E(x')-E_{\text{prev}})/T}$  ▷ (4)
4:    $x_{j+1} \leftarrow x'$ ;  $E_{\text{prev}} \leftarrow E(x')$ ;  $x_{\text{prev}} \leftarrow x'$ 
5:   if  $E(x') < E_{\text{best}}$  then
6:      $x_{\text{best}} \leftarrow x'$ ;  $E_{\text{best}} \leftarrow E(x')$ 
7:   end if
8: else
9:    $x_{j+1} \leftarrow x_{\text{prev}}$  ▷ rejeita e volta à última aceita
10: end if
11:  $T \leftarrow \alpha T$  ▷ (5)
12: if  $T < T_{\text{freeze}}$  then
13:    $x_{j+1} \leftarrow x_{\text{best}}$ ; ativa modo congelado
14: end if
15: return  $x_{j+1}$ 

```

Algoritmo 2. Ciclo de decisão do ajuste dinâmico por simulated annealing (executado pelo *dispatcher* a cada janela de `SA_WIN` blocos).

O custo (3) é medido em tempo real sobre a própria execução, capturando estados transientes da máquina (throttling térmico, carga da CPU); nenhum modelo de desempenho *a priori* é necessário. Além disso, a aceitação probabilística (4) torna o SA robusto a mínimos locais espúrios da janela corrente. Para experimentos controlados, o modo automático pode ser substituído pela variável de ambiente `HSP_FIXED_FRAC` (0 = somente GPU, 1 = somente CPU), usada na Seção 5 para isolar cada modo.

3.4. Telemetria e trava térmica

Antes de cada lançamento de kernel, a rotina `ler_telemetria_gpu` lê temperatura e consumo via NVML [NVIDIA Corporation 2023]. Se a temperatura igualar ou exceder o limite configurado (84 °C padrão), o processo aborta com código de erro explícito, protegendo o hardware em execuções longas. Temperatura e consumo são registrados por varredura no log e no JSON, junto da contabilidade completa de pontos e sistemas lineares.

3.5. Transposição de Borda (*Edge Transpose*) para Varreduras Y e Z

Ao contrário da varredura X (onde as linhas residem contíguas na memória), as varreduras Y e Z exigem passos de memória (*strides*) de tamanho N e N^2 , respectivamente. Em ambientes com restrição de memória física e paginação ativa em disco (swap), a leitura dispersa de elementos com salto de até 8 MB ocasiona sucessivos *page faults*.

Para contornar esse gargalo, implementou-se o esquema de *Edge Transpose*: as threads do pool de CPU realizam a coleta e empacotamento paralelo das fatias não-contíguas da memória virtual em buffers intermediários lineares de 16 MB no host. Uma

vez linearizados, esses blocos contíguos são transferidos via `cudaMemcpyAsync` e processados diretamente pelo kernel pentadiagonal unificado da GPU, preservando o acesso coalescido sem sobrecarregar o barramento PCIe com transferências picadas.

4. Plataforma experimental e validação

4.1. Ambiente

Os experimentos foram executados em um nó do cluster LNCC (`virtual22.prjsieh.lncc.br`) com um processador **AMD EPYC 9124** (Zen 4, 16 núcleos / 32 threads, 1,5–3,71 GHz, cache L3 de 64 MiB, 125 GB de RAM) e duas GPUs NVIDIA RTX 5000 Ada Generation (32 GB GDDR6, arquitetura Ada Lovelace, `sm_89`, driver 580.65.06), utilizando sempre o device 0. Compilador CUDA 13.0 com `-O3 -arch=sm_89 -fmad=false` e OpenMP no lado do host; o `-fmad=false` desativa a contração multiplicação–adiciona, garantindo aritmética idêntica entre CPU e GPU e reprodutibilidade bit-a-bit entre os modos.

4.2. Protocolo de validação

A correção e a reprodutibilidade foram verificadas por checksum cumulativo dos buffers de saída. O checksum de referência é `1,88943960e+08`, reproduzido bit-idêntico (a) nas iterações amostradas 1, 300, 900 e 1000 do run completo, (b) nos modos híbrido, somente-GPU e somente-CPU (Tabela 2) e (c) em varreduras sanity com 1024 e 4064 blocos — o balanceamento adaptativo muda apenas a *distribuição* do trabalho, nunca o resultado numérico.

5. Resultados

5.1. Run de 1,061 trilhão de pontos

A execução de referência resolveu **1.061.191.680.000 pontos** ($1,061 \times 10^{12}$), correspondentes a **1.040.384.000 sistemas lineares** de ordem $n = 1020$, em 1000 varreduras sobre a malha de 1.040.384 linhas. A Tabela 1 resume a execução.

Tabela 1. Resumo da execução de referência (1000 varreduras, 4064 blocos).

Métrica	Valor
Pontos resolvidos	1.061.191.680.000 (1,061e12)
Sistemas lineares (n = 1020)	1.040.384.000
Tempo total (wall)	213,9 s
Tempo médio por varredura	163,1 ms
Vazão	4,96e9 pontos/s · 4,86e6 sistemas/s
GFLOPS (28 flops/ponto)	182,1
Checksum	1,88943960e+08 (bit-idêntico)
Temperatura máxima (trava 84 °C)	70 °C
Split convergido pelo SA	72% GPU / 28% CPU

A Figura 2 mostra a evolução do run: o tempo por iteração estabiliza em 160–170 ms após o warm-up do SA, e a temperatura da GPU cresce até o patamar de 70 °C, 14 °C abaixo da trava térmica.




Figura 2. Evolução do run de 1000 iterações: tempo por varredura e temperatura da GPU.




Figura 3. Tempo por varredura e vazão dos três modos de execução.

5.2. Híbrido versus modos puros

Para isolar o mérito do ajuste dinâmico, o solver foi executado nos três modos com a mesma configuração (4064 blocos, $n=1020$, 3 iterações): híbrido automático, somente-GPU (HSP_FIXED_FRAC=0) e somente-CPU (HSP_FIXED_FRAC=1). A Tabela 2 apresenta os resultados.

Tabela 2. Comparação dos modos de execução (mesma máquina, 3 iterações, checksum bit-idêntico nos três modos).

Modo	Tempo/varredura	GFLOPS	Split
Híbrido (SA automático)	163,1 ms	182,1	72% GPU / 28% CPU
Somente GPU	184,9 ms	160,7	100% GPU
Somente CPU	611,1 ms	48,6	100% CPU

O resultado é contra-intuitivo: o modo híbrido é 13% mais rápido que o somente-GPU. A explicação está na natureza memory-bound do kernel e no efeito combinado de (a) menos blocos por kernel (menos efeitos de fila e de última onda), (b) sobreposição real do trabalho de CPU com o da GPU, e (c) perfil de potência menos agressivo, que evita quedas de boost clock sob carga sustentada. O somente-CPU é $3,7\times$ mais lento, evidenciando o valor do offload mesmo em um nó com CPUs de alta contagem de threads.

Do ponto de vista prático, o SA encontrou esse equilíbrio *sozinho*, sem conhecimento prévio da máquina: o mesmo código convergiria para frações menores de CPU numa máquina com CPU mais lenta, e maiores com CPU mais rápida.

5.3. Comparação com o NPB-GPU na mesma placa

Para posicionar o solver frente à literatura, o NPB-GPU [Araujo et al. 2021] foi clonado, compilado (CUDA 13.0, sm_89) e executado na mesma GPU. Os resultados das classes B e C estão na Tabela 3.

Tabela 3. NPB-GPU SP na mesma RTX 5000 Ada (contagem oficial de flops da NAS, passo completo: RHS + 3 varreduras por iteração).

Classe	Tempo	GFLOPS (contagem NAS)
B (102^3 , 400 passos)	1,64 s	216,0
C (162^3 , 400 passos)	7,23 s	200,5

Ambas as classes passaram na verificação oficial de resíduos do NPB. A contagem NAS inclui a avaliação do RHS e as três varreduras por passo (850 flops/ponto), enquanto o estimador usado nas Tabelas 1 e 2 conta apenas a varredura pura (28 flops/ponto). Com essa ressalva, o solver proposto opera na mesma ordem de grandeza

de uma implementação de referência publicada na mesma GPU, com a vantagem de aritmética estrita ($-fmad=false$) e com uma métrica inequívoca adicional: 4,86 milhões de sistemas pentadiagonais por segundo.

5.4. Campanha controlada: EMA vs. SA, baselines e varredura de fração

O relatório consolidado do projeto dispõe de uma campanha de revalidação independente (duas rodadas, min-of-5, checksum bit-idêntico em 100% das execuções) comparando o controlador SA proposto com um controlador de referência por suavização exponencial (EMA) que *conhece* as taxas de CPU e GPU. A Tabela 4 e a Figura 4(a) mostram os tempos por escala.

Tabela 4. Campanha de revalidação EMA vs. SA (best-of-5 intercalado, checksum bit-idêntico 3,46459e+07 em 100% das execuções).

Blocos	EMA [ms]	SA [ms]	SA/EMA
64	6,66	6,59	99,0%
512	36,16	36,73	101,6%
1024	70,00	72,98	104,3%

O SA permanece dentro de 1–4% do EMA em todas as escalas (a variação de 4,3% em 1024 blocos reflete a variabilidade térmica intrínseca da máquina).

A Figura 4(b) mostra a varredura de fração forçada (HSP_FIXED_FRAC) em 1024 blocos, cada ponto com checksum bit-idêntico. O makespan é essencialmente plano (71–73 ms) para frações entre 0,3 e 0,9 — o controle *top-up* rebalanceia o *split* real para o equilíbrio 56/44 — e só os extremos forçados sobem (127,12 ms tudo-GPU e 147,63 ms tudo-CPU). Isso explica por que o SA converge para 0,40–0,44 sem risco de mínimos espúrios: a região ótima tem vale largo.




Figura 4. (a) EMA vs. SA; (b) fração forçada (SA automático em tracejado).




Figura 5. (a) Lotes por modo; (b) cuPentBatch vs solver (n=1020).

5.5. Mega-lote e comparação com cuPentBatch

A segunda otimização de agendamento — lançar os blocos de GPU em *mega-lotes* de MEGA=128 blocos com uma única sincronização — reduziu o tempo de despacho em 28–63% para todos os modos (Figura 5(a), Tabela 5) e bateu os recordes do projeto: SA automático a 42,44 ms em 1024 blocos (6,18 milhões de sistemas/s) e GPU-only via dispatcher a 47,30 ms.

Na comparação de kernel puro (Figura 5(b)), o kernel de produção (fatores pré-fatorados uma única vez e mantidos em registradores) resolve 262.144 linhas em 36,23 ms, superando o `pentSolveBatch` do `cuPentBatch` (38,31 ms) em 5% e o ciclo completo fatoração+solve do `cuPentBatch` (78,50 ms) em 2,17 $\times$, com checksums idênticos (7,63448874e+07) e resíduo $\|Ax - b\|_\infty < 1e-15$, provando que ambos resolvem exatamente o mesmo sistema. O layout interleaved do `cuPentBatch` re-lê a

Tabela 5. Impacto do mega-lote (1024 blocos; checksum inalterado em todos os modos).

Modo	antes (BATCH=8) [ms]	mega-lote [ms]	variação
GPU-only forçado	127,12	47,30	−63%
CPU-only forçado	147,63	147,87	0%
frac 0,5 forçada	71,20	51,52	−28%
EMA automático	70,00	47,12	−33%
SA automático	72,98	42,44	−42%

fatoração da DRAM a cada solve (10,7 GB); o kernel proposto lê os cinco vetores de coeficientes como argumentos do kernel. O “SOTA” warp-shuffle do tutorial reproduzido (10,9 ms) foi refutado por checksum divergente (8%) e não é considerado.

5.6. Comparativo Final dos 5 Métodos de Balanceamento no Mega-lote

Para consolidar os ganhos de desempenho, realizou-se uma campanha comparativa submetendo a malha de 1024 blocos aos cinco modos de escalonamento implementados (Figura 6). O checksum numérico manteve-se estritamente idêntico em todos os cinco regimes.




Figura 6. Tempo mínimo por varredura dos 5 métodos avaliados no mega-lote.




Figura 7. (a) Projeção C/D/E; (b) benchmark publicado vs. fase (asterisco).

O modo puramente em CPU (147,64 ms) estabelece o tempo base do processador, evidenciando a distância arquitetural. O particionamento Estático 50/50 (51,52 ms) mostra-se subótimo, amarrando a GPU para esperar a CPU. A execução Somente-GPU atinge 46,81 ms, definindo o teto de desempenho do hardware gráfico isolado. O escalonamento Reativo por Taxa (EMA) atinge um bom tempo (44,92 ms), mas sofre de miopia local em otimizações gulosas. Por fim, o **SA Adaptativo proposto** não apenas escapa de vales subótimos (graças à aceitação de Metropolis), como encontra o ponto dinâmico de balanceamento (ex.: 789 blocos para GPU e 235 para CPU), atingindo o recorde da plataforma de 35,89 ms. Este resultado comprova a premissa de que cooperar com a CPU mascara o gargalo do barramento e eleva a vazão global para cerca de **7,30 milhões de sistemas resolvidos por segundo**.

5.7. Projeção para as classes do NPB SP e estado da arte

Com as taxas medidas (3,75M sistemas/s pelo EMA; 4,86M/s no mega-lote com SA), o relatório projeta a *fase pentadiagonal* das classes do NPB SP (três varreduras $\times N^2$ linhas $\times$ passos): Classe C (162^3 , 400 passos) $\approx 4,2$ s; Classe D (408^3 , 500 passos) $\approx 66,6$ s; Classe E (1020^3 , 500 passos) $\approx 416,5$ s (Figura 7(a)). A Figura 7(b) posiciona esses números frente aos tempos publicados do SP Classe C completo (benchmark inteiro, incluindo RHS e comunicação), de 29,3 s (Titan) a 483,24 s (serial). Embora a comparação seja estrita à fase pentadiagonal e não ao benchmark completo, ela evidencia

que a fase dominante de uma malha com mais de 1 bilhão de pontos (Classe E) é executável em segundos em um único nó heterogêneo, escala que a especificação original do NPB projetou para execução distribuída em sistemas de mais de 1000 processadores em paralelo [Bailey et al. 1993].

5.8. Validação Transgeracional e Resiliência Out-of-Core

Para avaliar a portabilidade e a robustez do despachante adaptativo frente a variações severas de hardware, o solver com a malha de $1,061 \times 10^9$ pontos (4064 blocos, $n = 1020$) foi submetido a execução em uma plataforma restrita (CPU quad-core, 3 threads úteis e GPU NVIDIA GeForce GTX 660 com arquitetura Kepler sm_30 e 2 GB de VRAM) sob regime ativo de paginação em disco (swap em SSD).

O mecanismo de streaming em mega-lotes permitiu o processamento contínuo da malha sem estouro de memória física de vídeo (VRAM). Sob contenção de barramento e alta latência de disco no host — na qual o tempo médio de resposta da CPU degradou transitoriamente para 138,9 ms/bloco —, o controlador SA detectou o afogamento em tempo real e redirecionou dinamicamente o fluxo para a GPU (1,38 ms/bloco), despachando 1586 blocos para o dispositivo e concluindo o ciclo completo em 90,87 s. O checksum final reproduziu exatamente o valor de referência ($1,889440 \times 10^8$), comprovando a bit-identidade estrita entre gerações de silício (sm_30 vs. sm_89) e a tolerância a ruído sistêmico.

6. Discussão

Eficiência do ajuste dinâmico. A evidência empírica mais forte é que o modo automático superou os dois modos fixos na mesma máquina, validando a hipótese central: o custo real de cada fração é uma função não-monótona do estado transiente da máquina, inacessível a modelos estáticos — apenas a medição em tempo real com busca heurística (SA) captura o ótimo. O custo de adaptação é pequeno (uma janela de SA_WIN blocos, custo de medição negligenciável frente à varredura), e o modo congelado ($T < T_{freeze}$) garante estabilidade em execuções longas.

Eficiência de Recursos. O gargalo de memória de matrizes bandadas não exige escalonamento horizontal massivo. A combinação de lista livre, fatoração LU e ajuste por SA alcança vazões de trilhões de pontos em nós de trabalho únicos.

6.1. Resiliência Out-of-Core e Varreduras Tridimensionais

Na execução da Classe E (16,8 GB) num nó legado de 15 GiB e GTX 660 2 GB (swap 32 GiB SSD), a paginação gerou *thrashing*. O controlador EMA acumulou esse ruído (inflando a latência da CPU para 266,89 ms/bloco). O decisor SA filtrou os picos transitórios, contornando o afogamento (Tabela 6).

Tabela 6. Resiliência Out-of-Core (swap SSD). O EMA falha sob thrashing; o SA converge.

Eixo (Modo)	Tempo Varredura	Ruído CPU (Latência)	Split (α)	Vazão SSD
X (EMA Baseline)	94,12 s	266,89 ms/bloco	36% GPU / 63% CPU	—
X (SA Nativo)	90,87 s	138,97 ms/bloco	39% GPU / 61% CPU	186,6 MB/s
Y (SA Transpose)	91,98 s	estável	42% GPU / 58% CPU	184,4 MB/s
Z (SA Transpose)	212,43 s	afogamento I/O detectado	21% GPU / 79% CPU	79,8 MB/s

Para transpor os saltos descontínuos em Y e Z, as threads *host* linearizaram blocos em micro-buffers de 16 MB. Em Y, operou na taxa de X. Em Z (salto de 8 MB/ponto),

saturou I/O para 79,8 MB/s; o SA detectou a contenção e deslocou 79% para a CPU, concluindo a malha 3D.

Adaptação Autônoma a Acessos Descontínuos (X, Y, Z). O comportamento divergente entre os eixos X/Y e o eixo Z evidencia a utilidade prática do Simulated Annealing sem modelo prévio (*zero-profiling*). Enquanto nos eixos X e Y o empacotamento do *Edge Transpose* manteve a GPU saturada ($\alpha \approx 39\text{--}42\%$), a dispersão extrema de memória no eixo Z induziu contenção na controladora do SSD. Em sistemas estáticos, essa desaceleração forçaria a GPU a aguardar transferências lentas por DMA; o controlador SA, contudo, capturou o atraso relativo e priorizou a computação nos núcleos de CPU locais, provando que a meta-heurística reage tanto a variações térmicas de processamento quanto a gargalos físicos de subsistemas de armazenamento e memória virtual.

Limitações e Validação. (i) A comparação de GFLOPS com o NPB-GPU usa contagens de flops distintas (28 vs. 850 flops/ponto) e o NPB-GPU compila com `-use_fast_math`, enquanto o presente trabalho emprega aritmética estrita (`-fmad=false`); por essa razão, métricas invariantes de vazão (pontos/s e sistemas lineares/s) são adotadas como base primária. (ii) A margem de 13% sobre o modo somente-GPU é dependente do equilíbrio térmico e do barramento da máquina avaliada; o ganho arquitetural estrutural é a redução frente ao modo somente-CPU ($3,7\times$). (iii) O pipeline cobre agora as três direções espaciais (X, Y e Z) com *Edge Transpose*; a integração da avaliação do termo de fonte (RHS) ao passo temporal completo do NPB SP constitui a etapa subsequente.

7. Conclusão e trabalhos futuros

Este trabalho apresentou um solver pentadiagonal híbrido CPU–GPU com balanceamento adaptativo por simulated annealing, telemetria térmica e garantia de reprodutibilidade bit-a-bit. Na plataforma de referência (AMD EPYC + NVIDIA RTX 5000 Ada), o solver resolveu 1,061 trilhão de pontos em 213,9 s, atingindo vazão sustentada de 4,86 milhões de sistemas lineares por segundo e superando os modos puramente GPU (em 13%) e puramente CPU (em $3,7\times$). O kernel de produção superou o *cuPentBatch* em $1,05\times$ no solve e em $2,17\times$ no ciclo completo, mantendo resíduo $\|Ax - b\|_\infty < 10^{-15}$.

A validação em nó legado restrito confirmou a robustez *out-of-core* com transposição dinâmica (X, Y, Z), comprovando a independência de alocação monolítica. Sob gargalos de paginação e stride de 8 MB, o controlador SA adaptou o balanceamento autonomamente, democratizando malhas de 1 bilhão de pontos com bit-identidade em estações de entrada. Trabalhos futuros contemplam a expansão para multi-GPU e o passo temporal SP completo.

O código-fonte do solver, as campanhas de revalidação e o artigo estão disponíveis publicamente em <https://github.com/angualberto/Simulated-Annealing-para-o-Benchmark-NPB>.

Referências

- Araujo, G., Griebler, D., Rockenbach, D. A., Danelutto, M., and Fernandes, L. G. (2021). NAS parallel benchmarks with CUDA and beyond. *Software: Practice and Experience*, 51(11):2257–2280.
- Augonnet, C., Thibault, S., Namyst, R., and Wacrenier, P.-A. (2011). StarPU: a unified platform for task scheduling on heterogeneous multicore architectures. *Concurrency and Computation: Practice and Experience*, 23(2):187–198.

- Bailey, D., Barton, J., Lasinski, T., and Simon, H. (1993). The NAS parallel benchmarks. NASA Technical Memorandum 103863, NASA Ames Research Center, Moffett Field, CA, USA.
- Bailey, D. H., Barszcz, E., Barton, J. T., Browning, D. S., Carter, R. L., Dagum, L., Fatoohi, R. A., Frederickson, P. O., Lasinski, T. A., Schreiber, R. S., Simon, H. D., Venkatakrishnan, V., and Weeratunga, S. K. (1991). The NAS parallel benchmarks. In *Proceedings of the ACM/IEEE Conference on Supercomputing (SC'91)*, pages 158–165.
- Carroll, E., Gloster, A., Ó Náráigh, L., and Pang, K. E. (2019). cuPentBatch — a batched pentadiagonal solver for NVIDIA gpus. *Computer Physics Communications*, 241:79–89.
- Chang, L.-W., Stratton, J. A., Kim, H.-S., and Hwu, W.-M. W. (2012). A scalable, numerically stable, high-performance tridiagonal solver using GPUs. In *Proceedings of the International Conference on High Performance Computing, Networking, Storage and Analysis (SC'12)*. IEEE Computer Society.
- Golub, G. H. and Van Loan, C. F. (2013). *Matrix Computations*. Johns Hopkins University Press, Baltimore, MD, USA, 4th edition.
- Jackson, C. W. and Zubair, M. (2021). Improvements to a batch pentadiagonal solver on NVIDIA gpus. Technical report, NASA Langley Research Center. NASA Technical Report 20210009602; pôster no SIAM CSE21, virtual, 1–5 de março de 2021.
- Kang, J.-H., Kim, K.-H., Pan, X., and Choi, J.-I. (2023). PaScaL-TDMA 2.0: A multi-GPU-based library for solving massive tridiagonal systems. *Computer Physics Communications*, 291:108820.
- Kim, S., Kim, J., Ha, S., and You, D. (2025). A highly scalable TDMA for GPUs and its application to flow solver optimization. *arXiv preprint arXiv:2509.03933*.
- Kirkpatrick, S., Gelatt, C. D., and Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598):671–680.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., and Teller, E. (1953). Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6):1087–1092.
- NVIDIA Corporation (2023). *NVIDIA Management Library (NVML) Reference Manual*. NVIDIA Corporation, Santa Clara, CA, USA.
- Thomas, L. H. (1949). Elliptic problems in linear difference equations over a network. Technical report, Watson Scientific Computing Laboratory, Columbia University, New York.
- Tolmachev, D., Marti, P., Castiglioni, G., and Jackson, A. (2025). High performance solution of tridiagonal systems on the GPU. *ACM Transactions on Parallel Computing*, 12(2):5:1–5:25.